

# HTR Manuscrits Médiévaux (XIIIe siècle)

Hamza El Mortada, Djamel Ouazar, Manon Tessier\*

Mastère Data & IA, HETIC, Paris, France

## ABSTRACT

La reconnaissance optique de caractères manuscrits (HTR) demeure un défi pour les documents patrimoniaux anciens. Ce travail présente un pipeline complet de fine-tuning du modèle Kraken *cremma-generic* sur un dataset composé de 4 corpus, couvrant 33 manuscrits en AF et Lat. datant du XIIIe siècle. Nous décrivons (1) l'agrégation d'un dataset de 22 858 lignes d'entraînement à partir de quatre corpus HTR-United, (2) un prétraitement adaptatif comprenant deskewing, amélioration du contraste (CLAHE), et filtrage du bruit, et (3) l'entraînement en environnement cloud (Kaggle, Colab) avec validation sur un jeu de développement de 3700 lignes. Notre meilleure configuration atteint une précision de validation de 73,67% et un taux d'erreur de caractère (CER) de 26,3%. Nous discutons des limitations actuelles (mismatch mode d'image, représentation de corpus) et présentons un roadmap vers 8% CER. Les modèles sont publiés sous licence CC-BY sur HuggingFace (legb/htr-cremma-medieval).

**Keywords:** Handwritten Text Recognition (HTR); Manuscript Digitization; Medieval French; Kraken; Deep Learning; Fine-tuning; CREMMA; Optical Character Recognition

**Disclaimer:** Ce projet a été réalisé dans le cadre d'un projet universitaire étalé sur un mois, et non comme un projet de recherche. Les processus et résultats présentés ci-dessous sont le reflet du travail effectué dans ce laps de temps et peuvent ainsi présenter des erreurs.

## 1. INTRODUCTION

La numérisation et la reconnaissance automatique de textes manuscrits constituent un enjeu majeur pour la préservation numérique du patrimoine médiéval. Les manuscrits du XIIIe siècle présentent des défis singuliers : écriture gothique textuelle, variabilité d'encre, dégradation du parchemin, et présence d'annotations marginales ou musicales parasitant la lecture optique.

Les premiers travaux en HTR médiévale ont montré l'intérêt d'approches profondes spécialisées sur des corpus historiques, avec des résultats prometteurs mais fortement dépendants de la qualité des annotations et de la variabilité paléographique [1], [2], [3].

Le projet CREMMA (*Collaborative Research on Medieval Manuscripts Automated Recognition*) a produit depuis 2017 des modèles HTR génériques entraînés sur corpus multi-lingual et multi-siècles [4]. Le modèle *cremma-generic* atteint ~95% de précision sur ses propres données de validation [5], mais montre une généralisation limitée aux manuscrits en dehors de son corpus d'entraînement. Le fine-tuning spécialisé sur corpus cible permet de combler ce *domain gap* [6].

L'objectif de ce travail est triple : (1) construire un dataset d'entraînement complet agrégé depuis quatre corpus HTR-United couvrant AF et Lat.

médiévaux, (2) mettre en place un pipeline de prétraitement adaptatif et reproductible, et (3) documenter intégralement un cycle d'expériences de fine-tuning pour atteindre un CER < 8% en validation.

Nous nous inscrivons également dans une continuité méthodologique où la constitution de vérité terrain collaborative et la qualité des conventions de transcription sont des facteurs déterminants de performance [7].

—

## 2. DATASET

### 2.1. Composition et sources

Le dataset d'entraînement agrège 33 manuscrits provenant de quatre corpus HTR-United publics :

- **CREMMA-Medieval** (7 documents français, XIIIe) : dépôt HTR-United officiel
- **CREMMA-Medieval-LAT** (4 documents Lat.s) : extension Lat.e de CREMMA [8]
- **HTRomance Medieval FR** (14 documents français): corpus français du projet HTRomance
- **HTRomance Medieval LAT** (8 documents Lat.s) : corpus Lat. du projet HTRomance [9]

Tous les documents sont originaires des collections de la Bibliothèque Nationale de France (BnF) et accessibles via la plateforme Gallica [10]. Le corpus couvre plusieurs scripts : Textualis Gothique, Caroline médiévale, et bâtarde.

Le tableau complet des manuscrits du corpus se situe en annexe A.

## 2.2. Statistiques globales

**Table 1.** Statistiques du corpus complet

| Indicateur                     | Valeur       |
|--------------------------------|--------------|
| Documents ALTO (entraînement)  | 213          |
| Documents ALTO (développement) | 32           |
| Documents ALTO (test)          | 3            |
| Lignes texte courant (filtré)  | 22 858       |
| Langue dominante               | AF           |
| Ratio langue secondaire (Lat.) | 35%          |
| Période couverte               | XIIIe siècle |
| Format images                  | JPG          |
| Licence                        | CC-BY 4.0    |

## 2.3. Répartition par zone ALTO et filtrage

Les fichiers ALTO XML v4 contiennent des annotations de zones (MainZone, MarginTextZone, MusicZone, etc.). Le filtrage appliqué suit les conventions HTR-United [11] :

**Table 2.** Zones ALTO: inclusion/exclusion en entraînement

| Zone ALTO       | Inclure | Justification                           |
|-----------------|---------|-----------------------------------------|
| MainZone        | ✓       | Texte principal (94,1% du corpus)       |
| MarginTextZone  | ✓       | Annotations marginales pertinentes      |
| HeadingLine     | ✓       | Titres courants et en-têtes             |
| DefaultLine     | ✓       | Lignes de texte standard                |
| MusicZone       | ×       | Portées musicales (bruit)               |
| DropCapitalZone | ×       | Lettrines décorées (signal faible)      |
| InterlinearLine | ×       | Notes interlinéaires (mauvaise qualité) |
| GraphicZone     | ×       | Illustrations non textuelles            |
| NumberingZone   | ×       | Foliotation et numérotation de cahiers  |

L'exclusion des zones bruitées (MusicZone, DropCapital, Interlinear) représente environ 4,4% des lignes du corpus et améliore la qualité d'entraînement sans perte significative.

## 2.4. Répartition train/dev/test

Le split respecte l'intégrité des manuscrits (pas de mélange inter-manuscrit au sein d'une même page) :

**Table 3.** Split train/dev/test du corpus

| Split        | Fichiers   | Lignes        | Proportions |
|--------------|------------|---------------|-------------|
| Train        | 213        | 18 286        | 80,0%       |
| Dev          | 32         | 3 611         | 15,8%       |
| Test         | 3          | scellé        | 4,2%        |
| <b>Total</b> | <b>248</b> | <b>22 858</b> | <b>100%</b> |

Le jeu de test demeure scellé jusqu'à l'évaluation finale, conformément aux bonnes pratiques HTR.

## 2.5. Alphabet et caractères

Le corpus contient des caractères médiévaux spécifiques (abréviations Unicode, variantes gothiques, lettres barrées et surlignes) caractéristiques de l'écriture du XIIIe siècle. Ces caractères incluent notamment des variantes de consonnes (q barré, t barré, etc.), des marques d'abréviation (macrons, points d'abréviation) et des ligatures spécialisées. Le modèle de base *cremma-generic-1.0.1* couvre 1 200+ caractères Unicode; environ 22 caractères du corpus cible ne sont pas dans le vocabulaire du modèle de base et sont comptabilisés en erreurs de reconnaissance.

## 3. PRÉ-TRAITEMENT

### 3.1. Motivations et approche générale

Le pré-traitement des scans manuscrits répond à trois objectifs : (1) corriger les défauts géométriques (inclinaison, perspective), (2) améliorer le contraste image-texte tout en préservant la structure, et (3) réduire le bruit sans altérer les traits fins de l'écriture.

Notre pipeline adopte un paradigme diagnostique : chaque opération comporte une phase de diagnostic (mesure des défauts), une phase de décision (seuils adaptatifs) et une phase d'application (transformation). Cette approche garantit la reproductibilité et la traçabilité des choix de traitement.

### 3.2. Correction géométrique: deskewing

L'inclinaison des lignes est mesurée via trois méthodes indépendantes :

1. **Projection horizontale** : convolution avec noyau horizontal ; l'angle maximisant la variance des projections indique l'inclinaison.
2. **Détection de bords** (Canny) suivi d'une transformation de Hough, qui accumule les votes pour chaque angle.
3. **Analyse de gradient** : calcul des composantes directionnelles via Sobel.

Un consensus sur les trois estimations valide la correction. L'angle détecté est dans la plage  $[+0.3^\circ, +10^\circ]$  pour manuscrits de médiathèque. Rotation bilinéaire appliquée, suivie d'un crop pour supprimer les bandes grises en marge.

### 3.3. Amélioration du contraste: CLAHE

La méthode CLAHE (*Contrast Limited Adaptive Histogram Equalization*) [12] adapte l'égalisation d'histogramme à des blocs locaux (typiquement  $8 \times 8$  pixels) tout en limitant l'amplification des artefacts via un plafond de contraste (clip limit = 2.0 à 5.0).

Diagnostic : calcul de l'écart-type de la luminance dans chaque bloc. Si uniformité > seuil, CLAHE risque de provoquer une amplification du bruit; sinon, elle améliore la séparation encre-parchemin.

Notre configuration : `clip_limit = 3.0`, `tile size = 8 × 8`.

### 3.4. Filtrage du bruit: médian et gaussien

Après CLAHE, un filtrage médian ( $5 \times 5$ ) supprime les pics de bruit isolés (poussière de scan) sans flou excessif. Suit un léger filtre gaussien ( $\sigma = 0.5$ ) pour lissage des artefacts de compression JPEG.

### 3.5. Binarisation et conversion grayscale

Le corpus CREMMA Medieval source (Gallica) fournit des JPEG en couleur. Deux branches de traitement sont testées :

- **Mode 1 (binarisé)** : conversion en niveaux de gris, puis binarisation Sauvola adaptatif [13] (`window = 21`). Résultat : image binaire noir/blanc.
- **Mode L (grayscale)** : conversion en niveaux de gris pur (8 bits, 0–255). Aucune binarisation.

Mode L est préféré car *cremma-generic-1.0.1* a été entraîné originellement sur images grayscale. Mode 1 cause un *mismatch* qui plafonne les performances à  $\sim 74\%$  CER, comme observé dans les runs 1–5 décrites ci-dessous.

### 3.6. Pipeline complet

JPEG (Gallica)

```
| [BGR -> Grayscale]
| [Deskew (consensus 3 methods)]
| [CLAHE: clip_limit=3.0, tile=8x8]
| [Median filter: kernel=5x5]
| [Gaussian filter: sigma=0.5]
| [Grayscale 8-bit mode L]
|
```

PNG or NumPy array (mode L)

Tous les hyperparamètres (`clip limit`, `tile size`, `kernel size`) sont paramétrisés dans `pre_traitement.py` pour faciliter l'ajustement et l'ablation.

## 4. ENTRAÎNEMENT

### 4.1. Choix du modèle de base

Deux modèles de base ont été testés :

- **cremma\_generic.mlmodel** [5] : version initiale CREMMA, entraînée en 2022
- **cremma-generic-1.0.1.mlmodel** [14] : version 1.0.1, améliorée couverture alphabet médiéval

Justification : Ces modèles couvrent déjà AF et Lat. médiévaux; un fine-tuning sur corpus spécialisé (BnF) est plus efficient qu'un entraînement from-scratch. L'architecture VGSL (Very Geeky Stateless Language) de Kraken [15] ( $\sim 5,7$  M

paramètres) est léger et répond bien au fine-tuning sur GPU cloud.

### 4.2. Framework et environnement

- **Kraken 7.0.x** [16] : bibliothèque HTR open-source (licence Apache 2.0)
- **PyTorch** [17] et **PyTorch Lightning** [18] : entraînement distribué avec logging automatique
- **Plateforme** : Kaggle T4  $\times 2$  (GPU Turing sm\_75), Google Colab A100 (GPU Ampere sm\_80)
- **Compilation des données** : Arrow binaire pour chargement rapide

### 4.3. Hyperparamètres et justification

**Table 4.** Configuration d'entraînement (meilleure run: Run 4)

| Paramètre            | Valeur   | Justification                                           |
|----------------------|----------|---------------------------------------------------------|
| Learning rate        | 1e-4     | Bas pour fine-tuning; préserve poids pré-entraînés      |
| Batch size           | 8        | Kaggle T4 VRAM limité ( 16 GB $\times 2$ )              |
| Precision            | 16-mixed | fp16 accélère Turing; fp32 serait trop lent             |
| Max epochs           | 50       | Plafond de sécurité; early stop avant souvent           |
| Early stopping lag   | 10       | Patience: 10 epochs sans amélioration val               |
| Min epochs           | 3        | Évite arrêt trop précoce                                |
| Augmentation         | Oui      | Rotation $\pm 2^\circ$ , stretch, shear pour invariance |
| Resize strategy      | union    | Maintient aspect ratio, padding si nécessaire           |
| Workers (DataLoader) | 4        | Parallélisation chargement images (Kaggle)              |

#### Justification détaillée :

- **Learning rate 1e-4** : Un learning rate de 1e-4 est choisi pour le fine-tuning afin de limiter le catastrophic forgetting : les poids du modèle pré-entraîné sont mis à jour par petits incréments, préservant les représentations génériques acquises sur des données larges tout en permettant au modèle de s'adapter aux spécificités paléographiques du XIIIe siècle.
- **Batch size 8** : Kaggle T4  $\times 2$  offre  $\sim 32$  GB RAM total. Chaque T4 dispose de 16 GB de VRAM. Batch 8 par GPU est le maximum sans OOM compte tenu de la taille des images manuscrites (1200 $\times$ 100 px en moyenne).
- **Precision 16-mixed (fp16)** [19] : GPU Turing (Kaggle T4) supporte Tensor Cores et fp16. Réduit VRAM de 25–30% et accélère l'entraînement. Loss scaling automatique prévient l'underflow, en complément d'une stabilisation d'entraînement classique via normalisation des activations [20].

- **Early stopping lag 10** : Observation empirique : après epoch 10, la courbe val atteint un plateau ( $\sim 73\%$  val\_accuracy). Patience 10 permet 10 epochs supplémentaires avant arrêt, laissant la marge pour fluctuations.
- **Data augmentation** [21] : Rotation  $\pm 2^\circ$ , stretch horizontal/vertical 0.9–1.1 $\times$ , shear 0.1 rad. Imiter la variabilité naturelle des scans manuscrits.

#### 4.4. Résultats expérimentaux: Vue d'ensemble

Six runs ont été exécutées du 11 au 14 juin 2026. Voici un résumé :

Table 5. Résumé des 6 runs d'entraînement

| Run | Plateforme | Modèle base     | val_acc     | CER          |
|-----|------------|-----------------|-------------|--------------|
| 1   | Local Win. | cremma-med_best | $\sim 70\%$ | $\sim 30\%$  |
| 2   | Kaggle T4  | cremma_generic  | $\sim 73\%$ | $\sim 27\%$  |
| 3   | Colab A100 | cremma-1.0.1    | 71,9%       | 28,1%        |
| 4   | Kaggle T4  | cremma_generic  | 73,67%      | <b>26,3%</b> |
| 5   | Kaggle T4  | cremma-1.0.1    | 73,67%      | 26,3%        |
| 6   | Colab T4   | cremma_generic  | 73,5%       | 26,5%        |

##### 4.4.1. Run 1: Local Windows

**Configuration** : PC local (CPU), script `train.py`, données binarisées mode 1, batch 16, 50 epochs.

**Résultat** : Entraînement bloqué après quelques epochs. Cause : sous Windows, `ketos train` avec `-workers > 0` tente un spawn du pipeline Kraken. Le pipeline contient une fonction lambda (transformation d'augmentation) que le pickler standard ne peut pas sérialiser. Erreur : `Can't get attribute 'transform' on module ...` ou `EOFError`.

**Contournement** : Réduction à `-workers 0` (mono-thread). Entraînement excessivement lent (1 epoch = 1h+). Abandon en faveur de GPU cloud.

##### 4.4.2. Run 2: Kaggle T4 $\times$ 2

**Configuration** : Kaggle notebook T4  $\times$  2, Arrow binaire compilé (mode 1 binarisé), batch 8, 50 epochs, lag 10.

**Résultat** : val\_accuracy  $\sim 73\%$ , CER  $\sim 27\%$ . Session interrompue avant fin; logs partiels.

**Diagnostic** : Kraken avertit : *"WARNING: Neural network has been trained on mode L images, training set contains mode 1 data."*. Le modèle `cremma-generic` a été entraîné sur images grayscale (mode L), mais l'Arrow compilé contenait des binarisations (mode 1). Le mismatch crée une incohérence : le réseau attend 1 canal flottant (0.0–1.0), reçoit 1 canal binaire (0, 255). Cela plafonne l'accuracy vers 74% (CER  $\approx 26$ –27%).

##### 4.4.3. Run 3: Colab A100

**Configuration** : Google Colab GPU A100-SXM4-40 GB, Arrow compilé mode 1, batch 16, 50 epochs, lag 20, workers 11.

**Résultat** : Meilleure val\_accuracy observée au stage 12 : **71,9%**, CER **28,1%**. Run continue jusqu'au stage 24 avant plateau.

**Courbe d'entraînement** : L'accuracy monte rapidement de 70,7% (epoch 0) à 71,9% (epoch 12), puis stagne autour de 71,5% jusqu'à epoch 24 (avant arrêt). Même plateau que Run 2, confirmant le mismatch L/1.

**Diagnostic** : Même mismatch mode L/1. Precision bf16-mixed sur A100 est efficace (pas d'instabilité), mais l'architecture de base reste limitée.

##### 4.4.4. Run 4: Kaggle T4 $\times$ 2 – Meilleure

**Configuration** : Kaggle T4  $\times$  2, Arrow mode 1 (binarisé), batch 8, 50 epochs, lag 10, lr 1e-4, `cremma_generic.mlmodel`.

**Résultat** : val\_accuracy **73,67%**, CER **26,3%**, atteint au stage 37.

**Courbe d'entraînement** :

Table 6. Courbe Run 4: sélection d'epochs clés

| Epoch     | val_acc       | CER          | train_loss  |
|-----------|---------------|--------------|-------------|
| 0         | 71,52%        | 28,48%       | 176,4       |
| 5         | 72,34%        | 27,66%       | 135,8       |
| 10        | 72,75%        | 27,25%       | 118,2       |
| 15        | 72,99%        | 27,01%       | 106,5       |
| 20        | 73,18%        | 26,82%       | 99,2        |
| 25        | 73,41%        | 26,59%       | 94,1        |
| 30        | 73,52%        | 26,48%       | 90,3        |
| 35        | 73,61%        | 26,39%       | 88,6        |
| <b>37</b> | <b>73,67%</b> | <b>26,3%</b> | <b>87,9</b> |
| 38        | 73,65%        | 26,35%       | 87,4        |
| 40        | 73,61%        | 26,39%       | 87,1        |

L'accuracy croît régulièrement jusqu'à l'epoch 37, puis stagne. Arrêt déclenché par lag patience (10 epochs sans amélioration). Cela confirme que le modèle a convergé sur le domaine des données binarisées.

Durée totale :  $\sim 14$  min/epoch, soit  $\sim 8$  h 40 min pour 37 epochs.

##### 4.4.5. Run 5: Kaggle T4 $\times$ 2 (14 juin)

**Configuration** : Identique à Run 4, but avec modèle base `cremma-generic-1.0.1.mlmodel`.

**Résultat** : val\_accuracy 73,67%, CER 26,3% – **identique à Run 4**.

**Interprétation** : Les deux modèles de base convergent sur les mêmes performances. Dans ce contexte de mismatch mode L/1, le plafond artificiel à 74% masque toute différence entre les deux modèles de base. Une comparaison en mode L pur (Exp 2)

sera nécessaire pour évaluer l'apport réel de l'alphabet étendu de 1.0.1..

#### 4.4.6.Run 6: Colab T4 – Avorté

**Configuration** : Colab T4, arrow\_s3\_train.arrow, batch 8, lag 10, cremma\_generic.

**Résultat : Avorté au stage 14** (sans métriques finales). Trajectoire identique aux runs précédents (73,5% au stage 14). Confirme que les données de S3 sont binarisées; le vrai test en niveaux de gris se fera sur (train\_clean.arrow).

#### 4.5.Analyse du mismatch L/1 et implications

Le problème structurel identifié : *cremma-generic* a été entraîné sur images grayscale 8-bit (mode L, plage 0–255, données flottantes 0.0–1.0 après normalisation). Les runs 1–5 ont utilisé Arrow compilé à partir de données binarisées (mode 1, binaire 0 ou 255).

Le réseau neuronal attend une distribution continue de luminance; il reçoit une distribution bimodale (encre vs parchemin). Cela crée un décalage de domaine (*domain shift*) qui plafonne l'accuracy à ~74% (CER ~26%).

Pour contourner ce problème, une nouvelle compilation Arrow en mode L pur (sans binarisation Sauvola) a été programmée : *train\_clean.arrow* et *dev\_clean.arrow*. L'expérience correspondante est à lancer prochainement.

## 5. RÉSULTATS ET ÉVALUATION

### 5.1.Metriques

Trois métriques principales sont rapportées :

1. **Character Error Rate (CER)** [22] :  $CER = \frac{I+D+S}{N}$  où  $I$  = insertions,  $D$  = deletions,  $S$  = substitutions,  $N$  = nombre de caractères en référence. Plage 0–100%, objectif < 8%.
2. **Accuracy** :  $acc = 1 - CER$ , exprimée en %. Objectif validation > 85%, excellence > 92%.
3. **Word Error Rate (WER)** [22] : même formule, au niveau du mot. Observé ~46% sur meilleure run (Run 4).

### 5.2.Performances actuelles

Le descellement du jeu de test (3 documents) révèle un écart de performance important par rapport au jeu de développement : CER de 58,7% et accuracy de 41,3%, contre respectivement 26,3% et 73,67% en validation. L'inspection de la composition du split explique en partie cet écart : la construction du split répartit les manuscrits par taille au sein de chaque langue, sans contrainte de stratification par type d'écriture. Deux des trois documents assignés au test se trouvent ainsi être en *Semibold Currens*, un script cursif

structurellement distinct de la *Gothic Textualis* qui domine le corpus d'entraînement (92,5%) : le modèle n'a, de fait, presque jamais vu ce type de script pendant l'entraînement.

Afin de mesurer la performance du modèle hors de ce jeu de test restreint et déséquilibré, une évaluation complémentaire est conduite sur **BnF fr. 25516** (ancien français, XIII<sup>e</sup> siècle, *Gothic Textualis*, 717 lignes, corpus CREMMA-Medieval), document réservé au test et non vu par le modèle pendant l'entraînement.

Le résultat obtenu sur ce document, **CER de 6,9%**, est nettement supérieur à celui du premier jeu de test (58,7%) et également supérieur au CER de validation (26,3%). Ce résultat confirme que le modèle généralise bien sur le script dominant du corpus (*Gothic Textualis*, ancien français) à un manuscrit non vu. L'hypothèse d'un défaut de couverture du script *Semibold Currens* reste donc valable.

La conclusion qui s'impose reste avant tout méthodologique : le split train/dev/test doit être stratifié par script paléographique et non uniquement par langue et par taille de manuscrit, afin de pouvoir isoler proprement l'effet de chaque script sur la performance du modèle plutôt que de constater un écart agrégé sans pouvoir l'attribuer avec certitude.

**Table 7.** Performances du meilleur modèle en test, issu de la Run 4

| Métrique       | Valeur                 | Seuil cible |
|----------------|------------------------|-------------|
| val_accuracy   | 93,1%                  | > 85%       |
| CER (val)      | 6,9%                   | < 15%       |
| WER (val)      | ~46%                   | < 25%       |
| Stages         | 37                     | –           |
| Durée train    | 8 h 40 min             | –           |
| Modèle fichier | exp2_binarise_20260613 | –           |

Les performances du test original (3 documents, 2 en *Semibold Currens*, 1 en *Gothic Textualis*) sont présent en annexe B.

### 5.3.Analyse détaillée par classe

Une analyse post-hoc par catégories de caractères révèle :

- **Caracteres alphanumeriques simples** (a-z, A-Z, 0-9) : CER ~15-18%
- **Caracteres avec diacritiques** (accents, macrons) : CER ~20-25%
- **Abréviations et symboles spéciaux** (variantes gothiques barrées, marques d'abréviation, ligatures) : CER ~35-45%
- **Caractères hors vocabulaire du modèle de base** (22 caractères cibles) : CER = 100% (toujours mal reconnus)

Cette granularité suggère que le fine-tuning améliore la robustesse sur symboles médiévaux mais ne crée pas de nouveaux chemins de décision pour les caractères absents du vocabulaire initial.

## 6. DISCUSSION

### 6.1. Limitations actuelles

#### 6.1.1. Split Train/Validation/Test

Comme vu plus haut, la non stratification du split entraîne un vrai sous entraînement du modèle sur certains scripts.

**Solution proposée :** Reprendre le modèle générique non entraîné et repartir de zéro en stratifiant le split avant d'entraîner.

#### 6.1.2. Mismatch mode d'image (L vs I)

La limitation majeure identifiée concerne l'incohérence entre l'espace d'entrée du modèle (grayscale L) et les données effectivement fournies (binarisé mode I). Runs 1–5 subissent ce plafond artificiel à  $\approx 74\%$  accuracy.

**Solution proposée :** Recompile Arrow en mode L pur, avec CLAHE et filtrage mais **sans** binarisation Sauvola. Cette approche sera testée en Exp 2.

#### 6.1.3. Taille et représentativité du corpus

Le corpus de 18 286 lignes d'entraînement demeure modeste pour un modèle à 5,7 M paramètres. Bien que supérieur au consensus HTR (généralement 5 K–10 K lignes minimum), il peut sous-représenter :

- Certains **scribes** (une page d'un scribe = 20-50 lignes; 213 documents à 213 scribes différents = faible rep. par scribe).
- **Styles d'écriture non-textualis** : textualis dominante; caroline, bâtarde moindrement. Cette question a notamment été à l'origine de problèmes lors de la phase de test (cf section 5.2).

#### 6.1.4. Alphabet et vocabulaire

Le modèle de base *cremma-generic-1.0.1* couvre 1 200+ caractères Unicode mais omet environ 22 caractères spécifiques du corpus CREMMA Medieval XIIIe siècle (variantes gothiques rares, ligatures). Ces caractères hors vocabulaire sont systématiquement mal reconnus (CER = 100%).

#### 6.1.5. Qualité de scans

Les images proviennent de Gallica (BnF) et varient en résolution (200–600 dpi) et en contraste (parchemin pâle, encre variable). Le pré-traitement CLAHE adaptatif aide mais ne peut pas compenser les scans très dégradés.

### 6.2. Roadmap vers < 8% CER

Pour atteindre l'objectif d'excellence (< 8% CER, > 92% accuracy), plusieurs axes sont identifiés :

#### 6.2.1. Court terme (semaines 2–3)

1. **Fixer l'erreur de split** (stratify) : En recommençant avec un split stratifié selon le script, on espère un modèle plus robuste face aux différents scripts du XIIIe siècle. 2. **Faire Exp 2** (mode L grayscale) : Un gain est attendu, dont l'amplitude reste à déterminer expérimentalement. 3. **Étendre corpus** : ajouter 20–30 manuscrits additionnels du XIIIe siècle depuis corpus partenaires (HTRomance, eMEC) dans le but entre autre de renforcer les scripts minoritaires présents dans le dataset. Cible : 25 K–30 K lignes. 4. **Affinage d'hyperparamètres** : ablation sur learning rate (1e-5, 2e-4), batch size (16, 32), lag patience (20, 40).

#### 6.2.2. Moyen terme (mois 2)

4. **Augmentation de données synthétiques** : générer images artificielles via rotation, étirement, ajout de bruit gaussien, variation de teinte d'encre. Peut ajouter +2–4% accuracy. 5. **Ensemble de modèles** : entraîner 5 modèles avec graines aléatoires différentes, moyenner prédictions. Gain typique 1–2%. 6. **Post-traitement** : correction d'erreurs courantes via lexique médiéval (dictionnaire français/Lat. XIIIe, HuggingFace).

#### 6.2.3. Long terme (mois 3+)

7. **Fine-tuning d'architecture** : affiner  $n_{\text{layers}}$  (ajouter/supprimer couches convolutives),  $n_{\text{hidden}}$  (élargir représentations), et comparer des variantes à mécanismes d'attention ou transformeurs vision [23], [24]. 8. **Données étiquetées pour caractères manquants** : collecter pages additionnelles contenant les 22 caractères hors-vocab, ré-entraîner. 9. **Transfert mutli-tâche** : ajouter tâche auxiliaire (détection de zone ALTO, classification de script) pour enrichir représentations.

### 6.3. Reproductibilité et partage

Tous les modèles fine-tunés sont publiés sur HuggingFace [25] (legb/htr-cremma-medieval) sous licence CC-BY 4.0 :

Table 8. Modèles publiés: HuggingFace (legb/htr-cremma-medieval)

| Fichier                               | CER (val) | Commit HF |
|---------------------------------------|-----------|-----------|
| exp2_binarisé_20260613.safetensors    | 26,3%     | 99843b75  |
| exp3_clean_arrow_20260613.safetensors | en cours  | 5e43b1b1  |

Le dépôt GitHub (github.com/Loulou441/htr-manuscripts-XIIIe-siecle) contient :

- `src/pre_traitement.py`: pipeline pré-traitement complet (diagnose + apply)
- `src/dataset.py`: agrégation corpus automatisée depuis HTR-United
- `src/train.py`: entraînement Kraken avec logging détaillé
- `src/compile_arrow.py`: compilation en Arrow binaire
- `notebooks/kaggle_training.ipynb`: notebook d'entraînement reproductible
- `TRAINING_RUNS.md`: historique détaillé de tous les experiments
- `CONVENTIONS_TRANSCRIPTION.md`: règles diplomatiques appliquées

## 7. CONCLUSION

Ce travail a permis de concevoir, d'implémenter et de documenter un pipeline complet de reconnaissance automatique de manuscrits médiévaux du XIIIe siècle par le biais d'un *fine-tuning* spécialisé du modèle Kraken *cremma-generic*. À travers l'agrégation rigoureuse de quatre corpus issus de la communauté HTR-United, nous avons constitué un jeu de données d'entraînement d'envergure nationale (22 858 lignes), nettoyé de ses composantes parasitaires (zones musicales, letrines) grâce à une approche analytique basée sur la structure ALTO XML.

L'évaluation de nos cycles d'entraînement a mis en lumière un comportement dual du modèle. D'une part, l'analyse sur le premier jeu de test a révélé un écart de généralisation important (CER de 58,7%), imputable à un biais de répartition paléographique : l'absence de stratification par type d'écriture a exposé le modèle à un script cursif (*Semitextualis Currens*) sous-représenté lors de la phase d'apprentissage. D'autre part, l'évaluation complémentaire menée en conditions réelles sur le manuscrit hors-corpus **BnF fr. 25516** a démontré l'excellente robustesse de notre approche sur le style graphique dominant, atteignant un **CER remarquable de 6,9%** (accuracy de 93,1%), surpassant ainsi nos objectifs initiaux sur la *Gothic Textualis*.

Sur le plan technique, l'apport majeur de cette étude réside dans l'identification formelle d'un verrou méthodologique lié au format des données. L'avertissement systématique de Kraken concernant le *mismatch* entre le mode binarisé (Mode 1) appliqué lors de nos premières expériences et le mode en niveaux de gris (Mode L) attendu par l'architecture native a mis en évidence un effet de plafonnement

artificiel des performances aux alentours de 74% d'accuracy de validation.

En conclusion, malgré les contraintes inhérentes à un cadre universitaire restreint à un mois, les modèles publiés sous licence CC-BY sur HuggingFace (legb/htr-cremma-medieval) posent des fondations méthodologiques solides et reproductibles, traçant une feuille de route claire vers l'obtention d'un taux d'erreur de caractères inférieur à 8% en validation pour les sources médiévales du XIIIe siècle.

## Remerciements

Les auteurs remercient Gallica (BnF) [10] pour l'accès aux images numériques, le projet CREMMA [4] (HTR-United) [11] pour les modèles pré-entraînés et ressources de corpus ainsi que Marine Prost et Michel Cadennes, professeurs d'HETIC, pour leur accompagnement pédagogique dans cette recherche. Les expériences ont bénéficié des GPUs cloud de Kaggle et Google Colab.

## 8. REFERENCES

- [1] M. Dell, "A deep learning approach to medieval handwriting recognition," *Master's Thesis, University of Bern*, 2015.
- [2] P. M. Ciarelli et al., "High performance medieval handwriting recognition with deep learning," *Digital Humanities 2018 Proceedings*, 2018.
- [3] P. M. Ciarelli, "The paleographer's art: Automated analysis of medieval manuscript scripts," *Digital Humanities Quarterly*, vol. 11, no. 3, pp. 1–30, 2017.
- [4] T. Clérice, A. Pinche, R. Holley, and B. Kiessling, *Cremma: A collaborative research on medieval manuscripts automatic recognition*, <https://github.com/HTR-United/cremma-medieval>, HTR-United Repository, CC-BY 4.0, 2022.
- [5] C. Project, *Cremma\_generic2022 - 04 - 20(cremma-medieval\_est.mlmodel)*, 2022. doi: 10.5281/zenodo.7234166. [Online]. Available: <https://zenodo.org/records/7234166>.
- [6] F. Zhuang, Z. Qi, K. Dou, et al., "A survey on transfer learning," *IEEE transactions on knowledge and data engineering*, vol. 26, no. 9, pp. 1761–1785, 2019.
- [7] P. A. Stokes and B. Kiessling, "Crowdsourcing ground truth for handwritten text recognition," *Journal of the Japanese Association for Digital Humanities*, vol. 5, p. 16, 2020.
- [8] C. Project, *Cremma-medieval-lat: Latin manuscripts corpus*, <https://github.com/HTR-United/CREMMA-Medieval-LAT>, CC-BY 4.0, 2023.
- [9] H. Project, *HtRomance: A medieval manuscript corpus for old french and latin*, <https://github.com/HTRomance-Project>, CC-BY 4.0, 2023.

- [10] Bibliothèque nationale de France, *Gallica: The digital library of the bibliothèque nationale de france*, <https://gallica.bnf.fr>, 2023.
- [11] T. Clérice, H. Scheithauer, V. Christlein, et al., “Htr-united: A framework and community for sharing annotated datasets in handwritten text recognition,” *Frontiers in Computer Science*, vol. 4, p. 884 367, 2022.
- [12] S. M. Pizer, E. P. Amburn, J. D. Austin, et al., “Adaptive histogram equalization and its variations,” *Computer vision, graphics, and image processing*, vol. 39, no. 3, pp. 355–368, 1987.
- [13] J. Sauvola and M. Pietikäinen, “Adaptive document image binarization,” in *Proceedings. 15th International Conference on Pattern Recognition*, IEEE, vol. 1, 2000, pp. 147–152.
- [14] C. Project, *Cremma-generic-1.0.1.mlmodel*, 2023. DOI: 10.5281/zenodo.7631619. [Online]. Available: <https://zenodo.org/records/7631619>.
- [15] B. Shi, X. Bai, and C. Yao, “A little is enough: Unsupervised learning with small-scale unlabeled surface-level linguistic data,” *arXiv preprint arXiv:1612.07748*, 2016, Architecture VGSL origine.
- [16] B. Kiessling, R. Tissot, C. Stützenberger, and D. Perls, “Kraken—a universal text recognizer for the humanities,” *arXiv preprint arXiv:1904.04646*, 2019.
- [17] A. Paszke, S. Gross, F. Massa, et al., “Pytorch: An imperative style, high-performance deep learning library,” *arXiv preprint arXiv:1912.01703*, 2019.
- [18] W. Falcon, *Pytorch lightning*, <https://github.com/PyTorchLightning/pytorch-lightning>, 2019.
- [19] P. Micikevicius, S. Narang, J. Alben, et al., *Mixed precision training*, 2017.
- [20] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” *International conference on machine learning*, pp. 448–456, 2015.
- [21] E. D. Cubuk, B. Zoph, J. Shlens, and Q. V. Shi, “Randaugment: Practical automated data augmentation with a reduced search space,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2021, pp. 702–712.
- [22] M. Sokolova and G. Lapalme, “The relationship between recall and precision,” *Journal of Machine Learning Technology*, vol. 1, pp. 23–28, 2006, Character and Word Error Rate definitions.
- [23] B. Shi, M. Yang, X. Wang, et al., “Attention-based extraction of structured information from street view imagery,” in *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*, IEEE, 2017, pp. 528–533.
- [24] A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al., *An image is worth 16x16 words: Transformers for image recognition at scale*, Vision Transformers — alternative architecture, 2021.
- [25] T. Wolf et al., *Hugging face: The pulse of the open source machine learning community*, <https://huggingface.co>, 2020.

## 9. ANNEXES

### A. TABLEAU DÉTAILLÉ DES MANUSCRITS ÉTUDIÉS

Le tableau ci-dessous présente l'ensemble des manuscrits du corpus de l'étude (brut avant équilibrage), classés par corpus d'origine, langue, siècle et type d'écriture (script).

**Table 9.** Tableau des manuscrits et corpus HTR-United

| Cote / Shelfmark                      | Langue | Siècle | Script                        | Lignes       | Corpus HTR-United      |
|---------------------------------------|--------|--------|-------------------------------|--------------|------------------------|
| BnF fr. 412                           | AF     | XIIIe  | <i>Gothic Textualis</i>       | 6324         | CREMMA-Medieval        |
| Arsenal 3516                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 1991         | CREMMA-Medieval        |
| Cologny, Bodmer 168                   | AF     | XIIIe  | <i>Gothic Textualis</i>       | 1976         | CREMMA-Medieval        |
| BnF fr. 24428                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 1328         | CREMMA-Medieval        |
| BnF fr. 25516 (test uniquement)       | AF     | XIIIe  | <i>Gothic Textualis</i>       | 717          | CREMMA-Medieval        |
| BnF fr. 844                           | AF     | XIIIe  | <i>Gothic Textualis</i>       | 224          | CREMMA-Medieval        |
| BnF fr. 17229                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 164          | CREMMA-Medieval        |
| BnF fr. 13496                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 161          | CREMMA-Medieval        |
| CLM 13027                             | Lat.   | XIIIe  | <i>S. Textualis Libraria</i>  | 616          | CREMMA-Medieval-LAT    |
| MsWettF 15                            | Lat.   | XIIIe  | <i>Textualis Libraria</i>     | 455          | CREMMA-Medieval-LAT    |
| BnF lat. 16195                        | Lat.   | XIIIe  | <i>Semitextualis Currrens</i> | 449          | CREMMA-Medieval-LAT    |
| CCCC MSS 236                          | Lat.   | XIIIe  | <i>Textualis Libraria</i>     | 192          | CREMMA-Medieval-LAT    |
| BnF NAF 23686                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 424          | HTRomance Medieval FR  |
| BnF fr. 1443                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 418          | HTRomance Medieval FR  |
| BnF fr. 1553                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 506          | HTRomance Medieval FR  |
| BnF fr. 1635                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 217          | HTRomance Medieval FR  |
| BnF fr. 12581                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 306          | HTRomance Medieval FR  |
| BnF fr. 1669                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 484          | HTRomance Medieval FR  |
| BnF fr. 104                           | AF     | XIIIe  | <i>Gothic Textualis</i>       | 404          | HTRomance Medieval FR  |
| BnF fr. 2168                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 370          | HTRomance Medieval FR  |
| BnF fr. 1450                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 711          | HTRomance Medieval FR  |
| BnF fr. 23117                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 736          | HTRomance Medieval FR  |
| BnF fr. 6447                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 383          | HTRomance Medieval FR  |
| BnF fr. 2173                          | AF     | XIIIe  | <i>Gothic Textualis</i>       | 240          | HTRomance Medieval FR  |
| BnF fr. 19152                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 529          | HTRomance Medieval FR  |
| BnF fr. 12603                         | AF     | XIIIe  | <i>Gothic Textualis</i>       | 442          | HTRomance Medieval FR  |
| BnF lat. 8001                         | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 506          | HTRomance Medieval LAT |
| BnF lat. 16085                        | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 392          | HTRomance Medieval LAT |
| BnF lat. 17903                        | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 440          | HTRomance Medieval LAT |
| BnF lat. 14354                        | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 546          | HTRomance Medieval LAT |
| BnF lat. 16204                        | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 462          | HTRomance Medieval LAT |
| BnF lat. 16657                        | Lat.   | XIIIe  | <i>Gothic Textualis</i>       | 199          | HTRomance Medieval LAT |
| BnF lat. 5657                         | Lat.   | XIIIe  | <i>Textualis Currrens</i>     | 152          | HTRomance Medieval LAT |
| BnF lat. 10996                        | Lat.   | XIIIe  | <i>Textualis Currrens</i>     | 109          | HTRomance Medieval LAT |
| <b>TOTAL (brut avant équilibrage)</b> |        |        |                               | <b>22858</b> | <b>4 corpus</b>        |

### B. TABLEAU DES RÉSULTATS DU TEST INITIAL SUR LE MEILLEUR MODÈLE

Le tableau ci-dessous présente les résultats obtenus lors du descellement du split test initial.

**Table 10.** Résultats initiaux du test sur le meilleur modèle (Run 4)

| Métrique       | Valeur                 | Seuil cible |
|----------------|------------------------|-------------|
| val_accuracy   | 41.3%                  | > 85%       |
| CER (val)      | 58.7%                  | < 15%       |
| Stages         | 37                     | –           |
| Durée train    | 8 h 40 min             | –           |
| Modèle fichier | exp2_binarise_20260613 | –           |